




System Architecture / RAG Pipeline

Arquitectura Cognitiva y RAG

Orquestando MongoDB Atlas, Supabase y Gemini
como un ecosistema unificado de inteligencia.

Strategic Decoupling

Separación de Preocupaciones

Para escalar sin fricción, el sistema divide el peso, la estructura y el pensamiento en tres capas especializadas. Evitamos penalizar el rendimiento aislando los binarios pesados.



Columna 1: Supabase Storage

Rol: Almacenamiento de Objetos

Función: Aísla archivos binarios pesados (ej. PDFs de 20MB, imágenes) de la base de datos.

Estado: Bucket configurado como private y seguro mediante service roles.



Columna 2: MongoDB Atlas

Rol: Base de Datos Documental

Función: Almacena texto estructurado, metadatos y vectores en documentos BSON.

Estado: Ágil e indexado.



Columna 3: Google Gemini

Rol: Motor Cognitivo

Función: El modelo text-embedding-004 genera embeddings exactos de 768 dimensiones.

Estado: Inteligencia activa y síntesis.

La Ventaja del **Modelo Documental**

El texto no es uniforme. El modelo relacional impone una rigidez transaccional, mientras que el enfoque NoSQL se adapta a la naturaleza fluida de los chunks (fragmentos de texto).

- Flexibilidad BSON (JSON binario): Cada documento auto-contiene su información de manera independiente.
- Metadatos Variables: Un fragmento puede referenciar un número de página; otro, un autor. El esquema se adapta sin romperse.
- Escalabilidad Inevitable: Crecimiento horizontal fluido y nativo mediante sharding.



SQL (PostgreSQL): Rigidez Estructural



MongoDB BSON: Adaptabilidad Orgánica

Indexación Vectorial Nativa

La búsqueda vectorial no es una extensión parcheada; es un servicio nativo que transforma arreglos flotantes en mapas de significado conceptual.


- **Conexión Directa:** A diferencia de bases relacionales que requieren extensiones (como pgvector), Atlas procesa las dimensiones matemáticamente desde el núcleo.
- **Calibración Milimétrica:** El índice se configura para coincidir exactamente con las 768 dimensiones que genera Gemini.
- **Activación Fluida:** Nombrado estratégicamente como `embedding_index`, el aprovisionamiento nativo en los servidores integra la capacidad en aproximadamente un minuto.



Cálculo de la Distancia Conceptual

¿Cómo determina el sistema qué fragmentos resuenan entre sí? A través de métricas matemáticas dentro del espacio vectorial.

Métrica		Mecánica	Cuándo Usarlo
Coseno (Cosine) [Recomendado]		Mide el ángulo entre dos vectores.	Ideal para Gemini. Absorbe las variaciones en la frecuencia o longitud del texto, preservando el significado exacto.
Euclidiana (Euclidean)		Mide la distancia en línea recta entre puntos.	Vital cuando la magnitud absoluta de los valores vectoriales es la variable crítica.
Producto Punto (Dot Product)		Multiplicación interna de los vectores.	Altamente eficiente, pero exige arquitectónicamente que todos los vectores estén normalizados previamente.




Ingestion Pipeline

Flujo de Ingesta

De la ambigüedad del archivo físico a la estructura matemática.

1. Recepción: El archivo original (ej. PDF) se almacena de forma segura en Supabase (Object Storage).
2. Procesamiento: El sistema extrae el texto plano y lo divide lógicamente en chunks.
3. Vectorización: Gemini procesa cada fragmento, asignándole un peso exacto de 768 dimensiones.
4. Estructura Final: MongoDB Atlas almacena el texto estructurado, sus vectores, metadatos y la referencia limpia (URL/Path) al archivo original en Supabase.




Query Pipeline

Flujo de Consulta

Recuperación de contexto de alta precisión para una síntesis inteligente.

1. La Duda Matemática: La pregunta del usuario se transforma en un vector utilizando el mismo modelo de Gemini.
2. Resonancia: MongoDB Atlas compara este vector contra la base de datos usando la similitud de Coseno.
3. Recuperación: Los fragmentos más relevantes y sus metadatos son extraídos casi instantáneamente.
4. Síntesis: Gemini recibe el contexto exacto filtrado y articula una respuesta conversacional, fundamentada y precisa.



The Artifact

El Sistema en Reposo y en Acción

La arquitectura no es una suma de partes, sino un solo artefacto cognitivo.

Supabase carga el peso físico.

MongoDB organiza la mente estructurada y la memoria vectorial.

Gemini aporta la cognición y la síntesis.

Un diseño tranquilo, preciso e inevitable. Construido para agentes, sistemas y el futuro de los flujos de trabajo autónomos.